

TP final : Analyse des ventes par ville

Livrables attendus

RENDU : Documentation des actions et de leurs retours

1. **DOCUMENTATION** : Pour chaque étape, le **contexte**, les **commandes lancées**, le **retour obtenu** (copie d'écran), et la **conclusion**, etc.
2. **LE CODE SOURCE**
3. **LES RÉSULTATS** : `part-00000` , requêtes Hive, requêtes HBase, et le `top10.txt` .
4. **LE GRAPHIQUE** Matplotlib (au format PDF).
5. **OPTIONNEL** : La matrice de contrôle (l'ossature du rapport).
 - qui ingère ?
 - qui déplace ?
 - qui stocke ?
 - qui calcule ?
 - qui sert ?

Sommaire

- **I. Objectif — les questions du TP**
- **II. Préparation de l'environnement**
- **III. MapReduce**
- **IV. HBase**
- **V. Visualisation**
- **VI. Hive**
- **VII. NiFi**

II. Préparation de l'environnement

Avant la chaîne de questions, remettez le cluster en route et préparez l'accès aux données.

1. Lancez les conteneurs Docker
2. Ouvrez un terminal dans le master
3. Lancez les processus du cluster et expliquez leurs rôles
4. Déposez le fichier de données dans le master
5. Vérifiez que le fichier est bien hdfs
6. Affichez les 5 premières et dernières lignes du fichier (depuis HDFS)
7. Analysez la source de données et réalisez un "dictionnaire des données"

III. MapReduce

Q1 – Quelles villes commandent le plus d'articles ?

1. Code Mapper
2. Code Reducer
3. Testez **localement**
4. Lancez le job sur le cluster
5. Les 5 premières lignes des parts (Part-00000, Part-00001, etc.)

Q2 – Quelle ville#année commande le plus d'articles ?

1. Code Mapper
2. Code Reducer
3. Testez **localement**
4. Lancez le job sur le cluster
5. Les 5 premières lignes des parts (Part-00000, Part-00001, etc.)

IV. HBase

Q3 – Retrouver le total d'articles d'une ville

1. Relancer Q1 avec un reducer qui écrit dans HBase avec happybase (rowkey = ville)
2. Vérifier par `hbase shell`
3. Noter le `count` et la valeur de `LE MANS`

V. Visualisation

1. Créer un script Python **séparé** (hors MapReduce) qui lit la table HBase via HappyBase (Thrift démarré)
2. Générer le graphique du **top 10 des villes** avec Matplotlib et l'exporter en **PDF** (`resultat.pdf`), plus un fichier texte (`top10.txt`) pour vérifier le classement
3. Vérifier que les totaux affichés sont les **mêmes que ceux trouvés aux questions précédentes** (cohérence entre les outils)
4. Récupérer les livrables sur votre poste : sorties des jobs (`part-00000`) et graphique PDF (détaillez la procédure)

VI. Hive

Q4 – Le même classement en SQL (validation croisée)

1. Préparer les données au format attendu par Hive : un **TSV sans en-tête** ne gardant que les colonnes utiles
2. Déposer ce TSV dans un **répertoire HDFS dédié**
3. Créer la **base** puis une **table externe** dont le schéma reflète les colonnes du TSV
4. Écrire la requête qui reproduit le **classement par ville** de Q1 – même agrégation, moteur différent
5. Écrire la requête qui reproduit le **classement par ville#année** de Q2
6. Comparer les résultats aux `part-00000` de Q1 et Q2 (validation croisée : mêmes lignes ?)
7. `EXPLAIN` une requête et noter ce que Hive exécute réellement (lien avec le moteur MapReduce)

VII. NiFi

Q5 – Ingérer au lieu d'un `put`

1. Déposer le mini-CSV dans le dossier d'entrée du flux
2. Vérifier le flux (GetFile → ConvertRecord → PutFile) et la sortie TSV
3. Déposer la sortie dans HDFS, là où Hive la lit
4. Re-compter dans Hive (le COUNT augmente)
5. Tracer le lineage dans Data Provenance (qui, quand, quoi, où)